

Sprawozdanie

1. Rekurencyjne odwracanie macierzy

Pseudo kod:



inverse(A):

if A jest w wymiarach 2x2:

return odwrócone A (według definicji)

Podziel macierz A na macierze A11, A12, A21, A22

A11_inv = inverse(A11)

S22 = A22 - A21 * A11_inv * A12

S22_inv = inverse(S22)

C1 = A11_inv * A12

C2 = S22_inv * A21 * A11_inv

B11 = A11_inv + C1 * C2

B12 = - C1 * S22_inv

B21 = - C2

B22 = S22_inv


Połącz B11, B12, B21, B22

Return B


Wykresy:

Zrezygnowaliśmy z testów dla macierzy większych od 256x256 z powodu czasu wykonania algorytmu.

Wykres zależności działań zmiennoprzecinkowych od rozmiaru mnożonych macierzy:



Wykres zależności czasu od rozmiaru mnożonych macierzy:



Szacowanie złożoności:

Oszacowana złożoność: $\log_2(n) * n^3$

Przyjęta złożoność algorytmu mnożenia macierzy metoda strassena: n^3

$\log_2(n)$ ← wynika z faktu, że w każdym rekurencyjnym wykonaniu funkcji dzielimy macierz na 4 części z których każda jest wymiarów $S/2 \times S/2$ gdzie $S \times S$ jest

początkowym rozmiarem macierzy

`n^3` ← bierze się ze złożoności algorytmu mnożenia macierzy metoda strassena, której użyliśmy w implementacji. Jest ona wykonywana w każdym wywołaniu rekurencyjnym głównej funkcji.

Testowanie poprawności porównując wynik z matlabem:

Funkcje odwracającą macierz testowaliśmy korzystając z zależności:

```
initial_matrix @ inverted_matrix = eye
```

gdzie:

- `initial_matrix` - pierwotna macierz
- `inverted_matrix` - odwrócona macierz
- `eye` - macierz jednostkowa

Implementacja rekurencyjnego odwracania macierzy wraz z zliczaniem operacji zmiennoprzecinkowych i dostosowywaniem rozmiaru macierzy

Do implementacji wykorzystano metodę Strassena z poprzedniego laboratorium.

```
def __inverseInner(self, A: np.ndarray):
    if A.shape == (1, 1):
        x = 1 / A[0, 0]
        self.__flops += 1
        return np.array([[x]])

    A11, A12, A21, A22 = split_matrix(A)

    # A11_inv = inverse(A11)
    A11_inv = self.__inverseInner(A11)

    # S22 = A22 - A21 @ A11_inv @ A12
    S22 = self.strassen.multiplyMatrices(A21, A11_inv)
    S22 = self.strassen.multiplyMatrices(S22, A12)
    S22 = A22 - S22
    self.__flops += math.prod(A.shape)

    # S22_inv = inverse(S22)
```

```

S22_inv = self.__inverseInner(S22)

# B11 = A11_inv @ (I + A12 @ S22_inv @ A21 @ A11_inv)
I = np.eye(A11.shape[0])
B11 = self.strassen.multiplyMatrices(A12, S22_inv)
B11 = self.strassen.multiplyMatrices(B11, A21)
B11 = self.strassen.multiplyMatrices(B11, A11_inv)
B11 = I + B11
self.__flops += A11.shape[0]
B11 = self.strassen.multiplyMatrices(A11_inv, B11)

# B12 = -1 * (A11_inv @ A12 @ S22_inv)
B12 = self.strassen.multiplyMatrices(A11_inv, A12)
B12 = self.strassen.multiplyMatrices(B12, S22_inv)
B12 = -1 * B12
self.__flops = math.prod(B12.shape)

# B21 = -1 * (S22_inv @ A21 @ A11_inv)
B21 = self.strassen.multiplyMatrices(S22_inv, A21)
B21 = self.strassen.multiplyMatrices(B21, A11_inv)
B21 = -1 * B21
self.__flops = math.prod(B21.shape)

return np.vstack((np.hstack((B11, B12)), np.hstack((B21, S22_inv))))

```

2. Rekurencyjna LU Faktoryzacja

Pseudo kod:



LU(A):

if A jest w wymiarach 2x2:

return sfaktoryzowane A

Podziel macierz A na macierze A11, A12, A21, A22

L11, U11 = LU(A11)

U11_inv = inverse(U11)

L21 = A21 @ U11_inv

L11_inv = inverse(L11)

U12 = L11_inv @ A12

S = A22 - A21 @ U11_inv @ L11_inv @ A12

L22, U22 = LU(S)

Połącz L11, L21, L22


Połącz U11, U12, U22

Return L, U


Wykresy:

Przeprowadzone analogicznie jak wyżej.

Wykres zależności działań zmiennoprzecinkowych od rozmiaru mnożonych macierzy:



Wykres zależności czasu od rozmiaru mnożonych macierzy:



Szacowanie złożoności:

Dwa rekurencyjne wywołania funkcji $O(n^2)$

Pięć mnożeń macierzy metodą Strassena $O(n^{\ln(7)})$

Odpowiedź to $O(n^{\ln(7)})$

Testowanie poprawności porównując wynik z matlabem:

Funkcję faktoryzującą macierz testowano mnożąc przez siebie macierze L i U wcześniej upewniwszy się, że mają one oczekiwaną postać:

```
L @ U = initial_matrix
```

gdzie `initial_matrix` to pierwotna macierz, a `L` i `U` to macierze wynikowe algorytmu.

Implementacja algorytmu LU faktoryzacji w pythonie.

Do implementacji wykorzystano wcześniej zaimplementowaną metodę odwracającą macierz oraz metodę Strassena mnożenia macierzy z poprzedniego laboratorium.

```
def __LUInner(self, A: np.ndarray):
    if A.shape == (1, 1):
        return np.array([[1]]), A

    A11, A12, A21, A22 = split_matrix(A)

    L11, U11 = self.__LUInner(A11)
    L11_inv = self.inverse.inverse(L11)
    U11_inv = self.inverse.inverse(U11)

    L21 = self.strassen.multiplyMatrices(A21, U11_inv)
    U12 = self.strassen.multiplyMatrices(L11_inv, A12)

    S = self.strassen.multiplyMatrices(A21, U11_inv)
    S = self.strassen.multiplyMatrices(S, L11_inv)
    S = self.strassen.multiplyMatrices(S, A12)
    S = A22 - S

    self.__flops += S.shape[0] ** 2 # one operation for every element on square matrix

    L22, U22 = self.__LUInner(S)

    return (
        np.vstack((np.hstack((L11, np.zeros_like(A12))), np.hstack((L21, L22)))),
```

```
np.vstack((np.hstack((U11, U12)), np.hstack((np.zeros_like(A21), U22))))  
)
```

2. Rekurencyjne obliczanie wyznacznika

Pseudo kod:

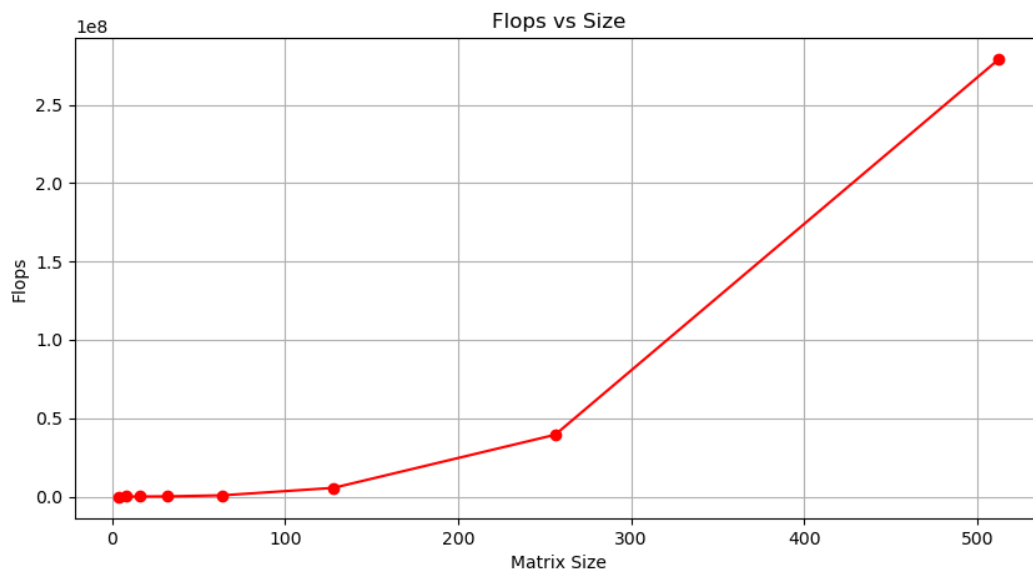


L, U = LU_faktoryzacja(A)
Det = iloczyn_elementow_na_przekatnej(U)

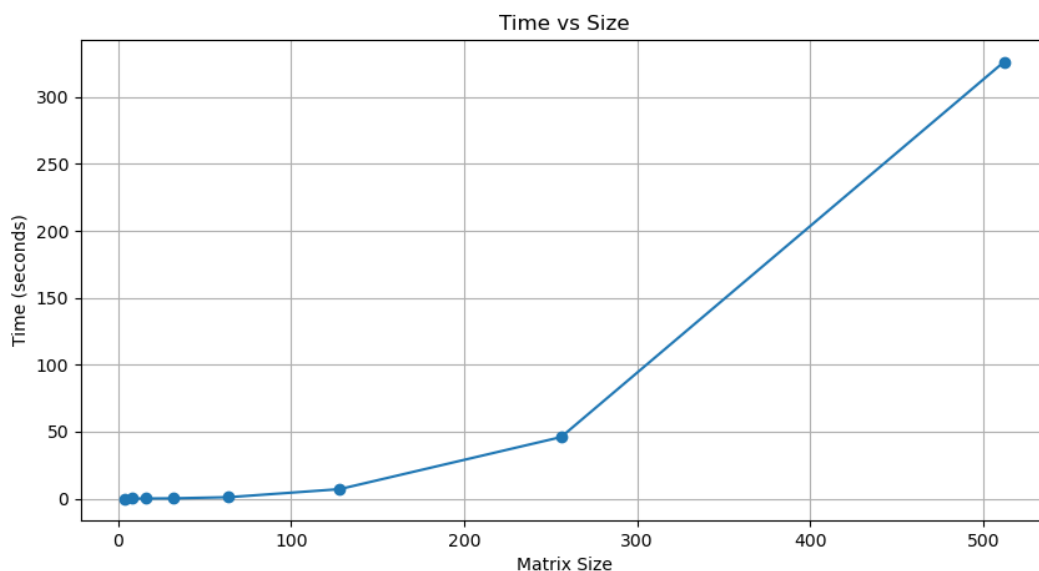
Wykresy:

Przeprowadzone analogicznie jak wyżej.

Wykres zależności działań zmiennoprzecinkowych od rozmiaru mnożonych macierzy:



Wykres zależności czasu od rozmiaru mnożonych macierzy:



Szacowanie złożoności:

Koszt faktoryzacji kodu to $O(n^{\ln(7)})$

Koszt sumowania iloczynów to $O(n)$

Co daje złożoność $O(n^{\ln(7)})$

Testowanie poprawności porównując wynik z matlabem:

Funkcję liczącą wyznacznik porównaliśmy licząc zwyczajnie wyznacznik odpowiadającą funkcję w matlabie.

Implementacja algorytmu liczącego wyznacznik w pythonie.

Do implementacji wykorzystano wcześniej zaimplementowaną metodę do LU faktoryzacji.

```
class DetCalculationEngine:
    __flops = 0
    lu = LUCalculationEngine()

    def resetCounter(self):
        self.__flops = 0
```

```
def getFlops(self):  
    return self.__flops  
  
def det(self, A: np.ndarray):  
    self.resetCounter()  
    self.lu.resetCounter()  
  
    L, U = self.lu.LU(A)  
    res = np.prod(np.diagonal(U))  
  
    self.__flops += self.lu.getFlops() + A.shape[0] - 1  
  
    return res
```